Informe preliminar: limpieza de datos, ingeniería de variables y preparación para la segmentación de clientes

Hallazgos de la limpieza inicial

El preprocesamiento inicial se aplicó sobre las dos bases suministradas, el maestro de clientes y la base transaccional, con el propósito de garantizar su consistencia antes de construir las variables explicativas. En términos generales, el proceso consistió en cinco pasos: depuración de duplicados, tratamiento de valores faltantes, validación de la integridad referencial y de la consistencia aritmética, consolidación del maestro a un registro por cliente y cruce de ambas bases en una única base unificada. Las fechas están anonimizadas, pero conservan el orden cronológico, por lo que las diferencias entre fechas son válidas para el análisis; el horizonte observado es de aproximadamente dos años y medio.

Maestro de clientes

Tras eliminar 39 filas estrictamente duplicadas, el maestro quedó con 552.670 registros. Sin embargo, estos correspondían a 492.551 clientes únicos, pues 60.119 identificadores aparecían en más de un registro con atributos distintos. Para obtener un registro por cliente, se ordenó la base por identificador y Primera Fecha, y se conservó el perfil más reciente (tipo de cliente, edad, género y autorización de tratamiento de datos) junto con la Primera Fecha más temprana. Esta regla se apoyó en un hallazgo de consistencia: en 39.017 de los clientes duplicados, la Primera Fecha del maestro resultó posterior a la fecha de su primer pedido en la base transaccional.

La variable Edad presentó valores faltantes en las empresas y en un único consumidor final (cliente_468723). A las empresas se les asignó el valor −1, con el fin de crear una barrera numérica que separe a este grupo de las edades reales y facilite que los algoritmos reconozcan su comportamiento diferenciado; al consumidor final se le imputó la mediana de edad de su grupo (45 años). Las edades de los consumidores finales van de 19 a 68 años. El género, en cambio, no se imputó: las empresas conservan su propia categoría y 54.910 consumidores finales se mantuvieron como «No identificado».

A partir de estos campos se crearon dos variables derivadas: el grupo generacional (Gen Z, Millennials, Gen X y Boomers, definidos según la edad en 2026, más la categoría Empresa) y un indicador binario de autorización de contacto (Habeas Data), que toma el valor 1 únicamente cuando el cliente respondió «SÍ». La respuesta «NO REGISTRA» (2,7 % de los registros) se trató como ausencia de autorización. El maestro consolidado quedó compuesto por 241.705 clientes Gen X (49,1 %), 154.679 Millennials (31,4 %), 46.768 empresas (9,5 %), 27.976 Boomers (5,7 %) y 21.423 Gen Z (4,3 %).

Base transaccional

La base transaccional contiene 2.632.164 registros, cada uno correspondiente a un producto dentro de un pedido, y no presentó filas estrictamente duplicadas. Abarca 5 negocios, 28 categorías, 106 subcategorías y 8.530 productos; el 60,4 % de los registros pertenece a Revestimientos e Instalación y el 24,9 % a Baños, mientras que Servicios representa apenas el 0,5 %. Bogotá, Valle, Antioquia, Atlántico y Cundinamarca concentran el mayor número de transacciones. Asimismo, la mayoría de los clientes

realiza pocas compras: cerca de 275.000 clientes registran un único pedido y la frecuencia decrece rápidamente a medida que aumenta el número de pedidos.

En cuanto a la completitud, los únicos campos con valores nulos fueron Cantidad (9.952 registros; 0,38 %) y Precio (150 registros; 0,006 %); Valor no presentó faltantes. Estos nulos se concentran en Revestimientos e Instalación, pues solo 1.160 registros con nulos pertenecen a otros negocios. Los registros se conservaron sin imputar en esta etapa: Valor, la variable monetaria de referencia, está completo, y Cantidad puede reconstruirse a partir de Valor y Precio si se requiere. Además, el valor «(No Value)» de la variable Región se reemplazó por la categoría «DESCONOCIDO».

Respecto a la consistencia aritmética, en el 99,61 % de las transacciones la diferencia entre Valor y el producto Cantidad × Precio supera un peso. Este resultado es coherente con la ofuscación de las variables, ya que Valor y Precio se multiplicaron por un factor y Cantidad por otro. Por tanto, se adoptó Valor como medida del total de cada transacción y Precio como precio unitario, sin intentar reconciliarlos.

Finalmente, no se encontraron valores negativos en Cantidad, Precio ni Valor; los registros menores o iguales a cero corresponden a ceros (136 en Cantidad, 260 en Precio y 410 en Valor). Estos registros se conservaron, dado que, según la documentación del reto, un Valor igual a cero representa una devolución o ajuste que puede tener asociada su compra positiva.

Integridad referencial y base unificada

Solo un cliente de la base transaccional no aparece en el maestro (0,00 %) y ningún cliente del maestro carece de transacciones. Como el reto deja a discreción del grupo la inclusión de ese cliente, se conservó mediante un cruce por la izquierda (left join) desde la base transaccional, de modo que sus atributos demográficos quedan nulos. El cruce no alteró el número de registros (2.632.164), lo que confirma que la consolidación previa dejó un único registro por cliente. La base resultante, de 22 columnas, incluye además de las variables originales la marca de devolución, el tipo de cliente, la edad, el género, el grupo generacional, la autorización de contacto y la Primera Fecha, y se exportó en formatos CSV y Parquet. La Tabla 1 resume los hallazgos y las decisiones de esta etapa.

Tabla 1

Resumen de hallazgos y decisiones del tratamiento inicial de datos

Aspecto	Hallazgo	Decisión
Filas duplicadas (maestro)	39 filas estrictamente duplicadas	Eliminadas
Clientes repetidos (maestro)	60.119 identificadores con más de un registro	Consolidación en 492.551 clientes únicos: perfil más reciente y Primera Fecha más temprana
Edad faltante	Empresas y un consumidor final (cliente_468723)	Empresas = −1; consumidor final = mediana del grupo (45 años)

Aspecto	Hallazgo	Decisión
Cantidad y Precio nulos	9.952 y 150 registros, concentrados en Revestimientos e Instalación	Conservados sin imputar; Valor está completo
Región «(No Value)»	Categoría sin información	Reemplazada por «DESCONOCIDO»
Valor ≠ Cantidad × Precio	99,61 % de las transacciones	Valor como total de la transacción; Precio como precio unitario
Valores iguales a cero	136 en Cantidad, 260 en Precio y 410 en Valor; sin negativos	Conservados como devoluciones o ajustes
Cliente sin registro en el maestro	1 cliente	Conservado mediante left join, con atributos demográficos nulos

Nota. Elaboración propia a partir del cuaderno de preprocesamiento.

Construcción de variables

Segmentación RFM

Como primera medida se aplicó el análisis RFM, que clasifica a los clientes según la recencia, la frecuencia y el valor monetario de sus transacciones (IBM, s. f.).

- **Recencia.** Mide cuán reciente fue la última compra del cliente, bajo el supuesto de que una adquisición más cercana en el tiempo aumenta la probabilidad de una nueva compra. Se calculó como los días transcurridos entre la última compra de cada cliente y la fecha de corte de la base, es decir, la fecha más reciente registrada.
- **Frecuencia.** Corresponde a la cantidad de veces que el cliente compra, bajo el supuesto de que quien más compra tiene mayor probabilidad de responder y de seguir comprando la marca después de su primera compra. Se calculó contando los pedidos distintos (ID Pedido) de cada cliente y no sus filas, dado que cada fila representa un producto comprado o devuelto y lo que interesa es la cantidad de pedidos efectivamente realizados.
- **Valor monetario.** Representa cuánto gasta el cliente en el horizonte de tiempo, bajo el supuesto de que quien más ha comprado en el pasado tiene más posibilidades de volver a comprar. Debe interpretarse con cautela, porque los clientes de mayor valor pueden comprar con menor frecuencia, pero adquirir productos más costosos. Se obtuvo sumando la columna Valor de los pedidos de cada cliente, lo que arroja el valor neto (compras menos devoluciones). Además, el monto de las devoluciones se extrajo en una columna aparte, pues un cliente que compró 100.000 pesos y otro que compró 120.000 y devolvió 20.000 tienen el mismo valor monetario, pero no el mismo comportamiento.

Siguiendo la metodología de Medina Lara et al. (2026), la recencia y el valor monetario se discretizaron por quintiles (1 a 5), donde 5 representa a los clientes con compras más recientes y a los que más han invertido, respectivamente. Dada la alta concentración de clientes con una sola compra o pocas compras, el puntaje de frecuencia se asignó mediante reglas fijas. Adicionalmente, se calculó un RFM ponderado con pesos de 40 % para la recencia, 20 % para la frecuencia y 40 % para el valor monetario. Esta ponderación responde a que el comportamiento de compra en Corona es de baja frecuencia y alto valor monetario, y a que la recencia pesa durante la ejecución de un proyecto de adecuación o remodelación, pero disminuye drásticamente cuando este termina; el esquema busca, así, identificar el momento del proyecto en que se encuentra el cliente.

Intensidad inter-categoría y diversificación del gasto

En el retail multicategoría, como el de Corona, las métricas RFM resultan insuficientes para explicar por sí solas el comportamiento del consumidor (Boston Consulting Group [BCG], 2025; Mastercard Economics Institute, 2024), por lo que se incorporaron métricas que evalúan la dispersión del gasto entre las líneas de negocio. Con base en el enfoque de intensidad de compra inter-categoría de Fritis (2014), se analizó la coocurrencia de productos o divisiones comerciales y el nivel de penetración cruzada del portafolio. Esta perspectiva se complementó con un índice Herfindahl-Hirschman (IHH) ajustado, que cuantifica el grado de diversificación del gasto del cliente; con la distribución del Share of Wallet (SOW) en cada uno de los cinco negocios de Corona; y con otras variables de diversidad del portafolio.

La intensidad inter-categoría mide la profundidad con la que un cliente explota el catálogo de la empresa. Resulta útil porque la frecuencia y el valor monetario pueden ocultar diferencias: dos clientes con la misma frecuencia y el mismo valor aportado pueden diferir en que uno compró en una sola categoría y el otro en varias. Esta dispersión permite perfilar al cliente y realizar análisis de espacios en blanco (*white space analysis*) para identificar necesidades no satisfechas y oportunidades de crecimiento, que luego alimenten estrategias de venta cruzada (*cross-selling*) y de venta de productos de mayor valor (*upselling*).

Ritmo de recompra y ventana de observación

La literatura sobre modelos probabilísticos en entornos no contractuales (Fader y Hardie, 2005a; Fader et al., 2005b) plantea que el comportamiento del cliente debe evaluarse según su ritmo intrínseco de recompra y la ventana de interacción observada. Un cliente que lleva tiempo sin comprar no necesariamente está inactivo si su ciclo natural de compra es prolongado, como ocurre en proyectos de remodelación o construcción de larga duración. Para modelar esta inercia temporal se implementaron tres métricas:

- **Días de antigüedad (*tenure*).** Tiempo transcurrido desde la primera compra registrada del cliente hasta la fecha de corte de la base (fecha de corte − Primera Fecha). Contextualiza el tiempo de vida del cliente en la marca.
- **Rango de días activos.** Ventana temporal real durante la cual el cliente realizó compras (última fecha − Primera Fecha). Distingue a los clientes con comportamiento concentrado en una ventana corta de aquellos con una relación sostenida en el tiempo.
- **Intervalo promedio inter-compra.** Velocidad media de recompra, en días, entre pedidos consecutivos.

Para evitar distorsiones en los clientes con una sola compra (Total Pedidos = 1), el intervalo promedio inter-compra se dejó como valor nulo (NaN) en lugar de 0 (Chen y Guestrin, 2016; Ke et al., 2017). Así se impide que los algoritmos de aprendizaje automático interpreten a los compradores de una única transacción como clientes con una velocidad de compra hiperactiva.

Movilidad, red y concentración

Las métricas RFM tampoco distinguen el rol operativo del cliente; por ejemplo, un cliente profesional o maestro de obra que se mueve entre varias obras frente a un consumidor final local (BCG, 2025; Mastercard Economics Institute, 2024). Para capturar esta dispersión operativa y la dependencia del canal, se estructuraron indicadores de movilidad y de concentración basados en la lealtad Top-1:

- **Movilidad geográfica y de red.** Conteo único de municipios, puntos de venta y asesores que han atendido al cliente. Niveles altos de dispersión señalan clientes móviles o corporativos con cobertura regional.
- **Índice de concentración en punto de venta (PDV).** Mide el grado de lealtad o dependencia hacia la tienda principal del cliente. Un valor cercano a 1,0 indica alta dependencia de una tienda física o del canal digital, por conveniencia geográfica o hábito.
- **Índice de concentración en asesor.** Evalúa la fuerza de la relación comercial directa entre vendedor y cliente. Un índice elevado refleja una venta asistida y personalizada de alto valor agregado (clave en proyectos complejos de arquitectura o remodelación), mientras que uno bajo describe compras no asistidas, transaccionales o multitarea.

Preparación de los datos para la clusterización

Tras esta primera etapa de ingeniería de variables se obtuvo una matriz de 42 columnas. No todas se utilizarán, pues es necesario evitar problemas como la multicolinealidad entre predictores, la exogeneidad y la asimetría severa. A continuación se describen los tratamientos definidos.

Valores nulos

Estructuralmente, los nulos solo pueden aparecer en la variable Intervalo_Promedio_Dias, que calcula el promedio de días entre pedidos consecutivos y, por tanto, no existe para los clientes con uno o cero pedidos. Estos valores se imputaron con el percentil 99,5 de la variable, un tiempo muy alto que refleja la realidad del negocio: un cliente con una sola compra tiene un intervalo de recompra teóricamente infinito, o muy largo, en el horizonte de tiempo actual.

Varianza casi nula

Se filtraron las variables con varianza casi nula, ya que no aportan capacidad de discriminación ni poder explicativo, mediante VarianceThreshold de la librería scikit-learn. El criterio se diferenció según la naturaleza de cada variable:

- **Binarias.** $\mathrm{Var}(X) = p(1 - p)$. Con $p = 0{,}01$, $\mathrm{Var}(X) = 0{,}01 \times (1 - 0{,}01) = 0{,}0099$. Si una categoría aparece en menos del 1 % o en más del 99 % de los clientes (varianza inferior a 0,0099), la variable no aporta poder discriminante y se elimina.
- **Continuas.** Como las escalas difieren, se aplicó un filtro preliminar, antes de normalizar, que elimina únicamente las columnas con varianza cero estricta ($\mathrm{Var}(X) = 0$).

- **Discretas y puntajes.** Dado que la varianza máxima teórica depende del rango de valores permitidos, la variable se elimina si más del 95 % al 99 % de la población se concentra en una sola categoría (por ejemplo, si el 99 % de los clientes tuviera Puntaje F = 1).

Asimetría y escalamiento

Fader y Hardie (2005a) muestran que la distribución del gasto monetario (M) y de la frecuencia de compra (F) presenta asimetría derecha y no se ajusta a la distribución normal. Para corregir esta y otras asimetrías, se adoptó el enfoque de Medina Lara et al. (2026): transformación log(1 + x) seguida de StandardScaler, aplicada únicamente a las variables temporales continuas (como Recencia o Rango de días activos) y a las variables monetarias o de volumen (como Valor_Monetario_Total o Total_Lineas_Compradas). Las variables ya acotadas en el intervalo [0,0; 1,0], como el índice IHH o la amplitud de portafolio, solo se estandarizan, porque el logaritmo distorsionaría su escala proporcional sin aportar simetría; los puntajes RFM y las variables de co-compra no se transforman.

Se recurrirá a la transformación de Yeo-Johnson (Feature-engine, s. f.) en lugar de log(1 + x) en dos casos: si el valor neto de las devoluciones de un cliente supera sus compras en la ventana analizada (situación que no se presenta en esta base, pero que sería posible en una base más grande) o si, tras la transformación, el coeficiente de asimetría de una variable continua se mantiene por encima de |1,0|. Esta transformación busca la potencia λ óptima que fuerza la simetría de una distribución normal. Por su parte, la estandarización Z-score, que lleva las variables a $\mu = 0$ y $\sigma = 1$, se justifica por su uso en el estudio de la Universidad de los Andes (Medina Lara et al., 2026), pues asegura que la escala de las variables no afecte su poder explicativo.

Valores extremos

Como se supone que el comportamiento de los ingresos sigue el principio de Pareto, se adoptó la metodología para datos de colas pesadas del Departamento de Economía de la University of Alberta (2022) y se limitaron los valores extremos al percentil 99,5, de modo que los compradores masivos no distorsionen los centroides de k-means. Este procedimiento, conocido como winsorización, reduce el efecto de los atípicos, estabiliza la varianza y mantiene intacto el número de observaciones, a costa de atenuar su señal: «La winsorización debilita la magnitud de la señal proporcionada por un atípico, pero retiene su asociación potencial con el choque de información» (University of Alberta, Department of Economics, 2022, p. 6; traducción propia).

Multicolinealidad

La multicolinealidad no es solo una limitación estadística: en k-means provoca una distorsión geométrica por sobreponderación. Como el algoritmo se basa en la distancia euclidiana para medir la similitud entre observaciones, dos variables altamente correlacionadas equivalen, en la práctica, a darle el doble de peso a esa dimensión en el espacio de características ([Autores], 2026).

Para diagnosticarla se construyó una matriz de correlación híbrida: correlación de Spearman para los pares que involucran variables continuas o discretas, y correlación de Pearson para los pares de variables binarias, que en ese caso equivale al coeficiente phi (ϕ), la métrica estándar de asociación entre variables binarias. Como paso previo, se filtraron las variables con correlación superior a 0,9, con el fin de eliminar de forma explícita las redundancias matemáticas triviales.

Dado que la matriz de correlación puede mostrar valores bajos aun cuando existe multicolinealidad multivariada oculta, el descarte no se basó directamente en el coeficiente de correlación, sino en el GVIF (*generalized variance inflation factor*), métrica estándar para modelos grandes con variables binarias o categóricas. Como el GVIF ajusta el cálculo según los grados de libertad (df) de cada variable, se utilizó la versión corregida GVIF^(1/(2·df)), que permite comparar de forma justa variables binarias y continuas, y se elevó al cuadrado para aplicar las mismas reglas de un VIF convencional. El proceso de descarte fue el siguiente:

1. Calcular el GVIF corregido (elevado al cuadrado) de todas las variables en un único modelo global.
2. Identificar la variable con el valor más alto, siempre que supere el umbral de 5.
3. Consultar en la matriz híbrida si esa variable presenta un coeficiente superior a 0,7 con otra variable específica. Si el problema es puramente bivariado (un par de variables casi idénticas), se elimina de inmediato una de las dos.
4. Entre dos variables ligadas, conservar la que ofrezca mayor interpretabilidad para el negocio o, como segundo criterio de desempate, la de mayor varianza explicada (R^2).
5. Eliminar la variable descartada y repetir el proceso hasta que ninguna supere el umbral.

Resultados preliminares

La depuración redujo la matriz de 42 columnas a 19 variables numéricas ortogonales, junto con tres columnas de metadatos (Cliente, RFM combinado y Negocio principal). De este modo se conserva una alta capacidad explicativa y se elimina la colinealidad que habría distorsionado la distancia euclidiana en k-means. Por etapa, los resultados fueron los siguientes:

- **Varianza casi nula.** Se eliminó la variable Devoluciones y los tres pares de co-compra con la línea SERVICIOS, dado que se presentaron en menos del 1 % de la población evaluada.
- **Redundancias triviales.** Se eliminaron ocho variables: Indice Concentracion PDV, Valor_Monetario_Total, Recibo Promedio Por Pedido, Indice Concentracion Asesor, Recencia, Rango Dias Activo, Indice IHH y Frecuencia_Pedidos. Valor_Monetario_Total es un casi duplicado del Puntaje M, al igual que Recencia del Puntaje R, y los índices de concentración resultaron redundantes. El filtro cumplió así el objetivo para el cual se creó.
- **GVIF iterativo.** Eliminó cinco variables: % Gasto REVESTIMIENTOS E INSTALACIÓN, por la trampa de suma constante entre los porcentajes de gasto, y Total_Lineas_Compradas, Cantidad Negocios Comprados, Puntaje F y Total_Unidades_Fisicas, por colinealidades multivariadas severas.

El vector resultante de 19 variables explicativas presenta un equilibrio deseable entre cinco ejes estratégicos del negocio, como se muestra en la Tabla 2.

Tabla 2

Variables explicativas finales por eje estratégico

Eje	n	Variables
RFM base	2	Puntaje R, Puntaje M

Eje	n	Variables
Ritmo y comportamiento temporal	4	Dias antiguedad, Intervalo_Promedio_Dias, Items Promedio Por Pedido, Promedio Negocios Por Pedido
Operativo, red y canal	3	Municipios_Distintos, Puntos_Venta_Distintos, Asesores_Distintos
Share of Wallet y categorías	3	% Gasto COCINAS, % Gasto PINTURAS E IMPERMEABILIZANTES, % Gasto BAÑOS
Co-compra intercategoría	7	Siete combinaciones binarias clave entre las líneas principales de negocio

Próximos pasos

La siguiente etapa es la exploración de la clusterización. Con base en el estudio de la Universidad de los Andes (Medina Lara et al., 2026), se utilizará la suma de errores cuadráticos intra-clúster (WCSS) para determinar el número óptimo de clústeres y el coeficiente de silueta para medir la separación y la coherencia de los grupos, y se evaluará la pertinencia de emplear fuzzy C-Means en lugar de k-means. Con los resultados de esta etapa se espera realizar un perfilamiento inicial de los clientes. La información de los clústeres se usará para proponer campañas a partir de los resultados, más que como variable explicativa del comportamiento del cliente.

Fuentes externas propuestas

Se identificaron bases externas que complementan el análisis. Dado que se asume un reto actual, se recomienda recolectar información de los últimos tres a cinco años, lo más actualizada posible según lo que se encuentre disponible. La Tabla 3 presenta las fuentes propuestas y su utilidad.

Tabla 3

Fuentes externas propuestas y su utilidad para el análisis

Bloque	Fuente	Utilidad
Construcción e inmobiliario	Licencias de construcción y m^2 licenciados (DANE)	Indicador adelantado: las licencias aprobadas hoy se traducen en compras de revestimientos, baños y pinturas dentro de 6 a 18

Bloque	Fuente	Utilidad
		meses.
Construcción e inmobiliario	Iniciaciones y entregas de vivienda VIS y No VIS (Camacol / Coordenada Urbana)	Las entregas de vivienda nueva, sobre todo en obra gris, impulsan de inmediato la compra de pisos, baños y cocinas.
Construcción e inmobiliario	Venta y traspaso de vivienda usada (Superintendencia de Notariado y Registro)	La compra de vivienda usada es el mayor disparador de remodelaciones en el segmento de consumidor final.
Financiamiento y consumo	Tasas de interés de crédito de consumo e hipotecario (Banco de la República)	La remodelación y los acabados de alto valor suelen financiarse con tarjetas de crédito o libre inversión; las tasas altas frenan las compras de ticket alto.
Financiamiento y consumo	Índice de Confianza del Consumidor, ICC (Fedesarrollo)	Incluye los subíndices «Disposición a comprar bienes durables» y «Disposición a comprar vivienda», que correlacionan con el consumo en las tiendas Corona.
Financiamiento y consumo	Tasa de desempleo e ingreso real de los hogares (DANE, GEIH)	Explica las variaciones del gasto en categorías no esenciales (por ejemplo, Mesa Servida o remodelaciones estéticas frente a reparaciones urgentes).
Sectorial y comercio minorista	Encuesta Mensual de Comercio Minorista, EMCM (DANE)	Permite aislar el comportamiento de líneas como «Artículos de ferretería, pinturas y productos de vidrio» o «Electrodomésticos y artículos para el hogar», y comparar a Corona con el resto del mercado.
Sectorial y comercio minorista	Índice de Costos de la Construcción de Vivienda, ICCV (DANE)	Refleja la variación de los costos de insumos y materiales; explica si las caídas en volumen se deben a incrementos en los

Bloque	Fuente	Utilidad
		precios de los materiales.
Sectorial y comercio minorista	Tasa Representativa del Mercado, TRM (dólar)	Afecta los costos de las materias primas importadas y la competitividad de los productos locales.

Referencias

Boston Consulting Group. (2025). *Market performance focus beats diversification*. https://www.bcg.com/publications/2025/market-performance-focus-beats-diversification

Chen, T., y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). ACM. https://arxiv.org/pdf/1603.02754

Cofré, N. F. (2014). *Introducción de una nueva metodología para la evaluación del impacto de la lealtad en la participación del gasto de los clientes en la industria de las farmacias*. Universidad de Chile. https://repositorio.uchile.cl/bitstream/handle/2250/117075/cffritis_nc.pdf?sequence=1

David, J., Lara, M., Javier, F., Sandoval, P., Alejandro, D., y Salcedo, V. (2026). *Modelos RFM y Conformal Prediction para la predicción temprana de clientes de alto valor en una reconocida empresa de ropa y calzado deportivo*. Universidad de los Andes. https://repositorio.uniandes.edu.co/server/api/core/bitstreams/abf52bd7-a3d7-4917-9821-35e39107895d/content

Fader, P. S., Hardie, B. G. S., y Lee, K. L. (2005a). RFM and CLV: Using iso-value curves for customer base analysis. https://faculty.wharton.upenn.edu/wp-content/uploads/2012/05/Rfm_clv_2005-02-16_accepted.pdf

Fader, P. S., Hardie, B. G. S., y Lee, K. L. (2005b). "Counting your customers" the easy way: An alternative to the Pareto/NBD model. *Marketing Science, 24*(2), 275–284. https://repository.upenn.edu/server/api/core/bitstreams/30cc31cc-5fe7-4f3c-b243-9e284d78a1a1/content

Feature-engine. (s. f.). *YeoJohnsonTransformer*. http://feature-engine.trainindata.com/en/latest/user_guide/transformation/YeoJohnsonTransformer.html

Galvani, V., y Li, L. (2022). *Outliers and momentum in the corporate bond market* (Working Paper No. 2022-03). University of Alberta. https://sites.ualberta.ca/~econwps/2022/wp2022-03.pdf

Harshvardhan, M., y Ranjan, P. (2026). *SmartCor: Intelligent correlation method selection for mixed variable types*. arXiv. https://doi.org/10.48550/arXiv.2607.22285

IBM. (s. f.). *Puntuaciones RFM a partir de datos de transacciones*. IBM SPSS Statistics 32.0.0. https://www.ibm.com/docs/es/spss-statistics/32.0.0?topic=analysis-rfm-scores-from-transaction-data

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., y Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. En *Advances in Neural Information Processing Systems* (Vol. 30).

Mastercard Economics Institute. (2024). *What is share of wallet (SOW)?* Mastercard. https://www.mastercard.com/content/mccom/eu/mt/en/news-and-trends/Insights/2024/what-share-wallet-sow.html